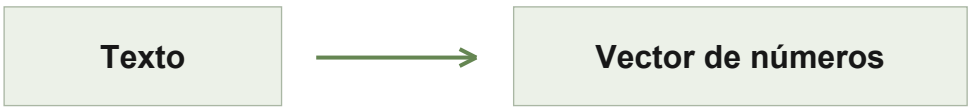
73.69 - Large Language Models

Apuntes de estudio

Unidad 2

Embeddings y similitud coseno

Representaciones vectoriales, contexto y magnitud



2Q - 2026

Apunte elaborado a partir de la clase 2

Índice

Unidad 2 - Embeddings y similitud coseno **3**

Representación vectorial del texto 3

Embeddings estáticos y contextuales 3

Comparación de vectores y similitud coseno 4

Ejemplo de cálculo 4

La magnitud y sus efectos 5

Fuentes de la clase 5

Unidad 2 - Embeddings

Representación vectorial del texto

Un **embedding** es una representación numérica de un elemento, como una palabra, una oración o un documento. Se expresa como un **vector**, es decir, una lista ordenada de números. Un modelo transforma los elementos de texto en puntos de un espacio continuo. Esa representación permite aplicar operaciones matemáticas al texto y comparar sus representaciones.

Por ejemplo, un modelo que representa oraciones puede ubicar «Necesito cambiar mi pasaje» cerca de «Quiero modificar mi reserva». Si aprendió a captar el significado, podría ubicar «Hoy llueve» más lejos. La cercanía depende del modelo y de la medida con que se comparen los vectores.

Texto → Modelo de embeddings → Vector

Embeddings estáticos y contextuales

Un **embedding estático**, como el de una palabra en Word2Vec, conserva el mismo vector para esa palabra una vez entrenado. El contexto del corpus ayuda a aprenderlo durante el entrenamiento. En cada uso posterior, el modelo consulta el vector fijo.

Un **embedding contextual** se calcula para una aparición concreta. En «fui al banco a retirar dinero» y «me senté en el banco de la plaza», las palabras vecinas permiten construir representaciones distintas para «banco». La clase ilustra esta diferencia con un ejemplo de «pizza» en dos oraciones.

Referencias de clase. Diapositivas 31 y 33–35. Transcripción, 18:32–18:50 para la motivación y 27:47–28:45 para la distinción entre representaciones.

Similitud coseno

Cómo comparar dos embeddings

Dados dos textos, primero se obtiene un vector para cada uno usando el mismo modelo de embeddings. La **similitud coseno** compara la dirección de los dos vectores mediante el coseno del ángulo que forman. Para calcularla, se divide el producto escalar por el producto de las normas euclidianas.

$$\text{similitud coseno}(a, b) = (a \cdot b) / (\|a\| \times \|b\|)$$

El producto escalar **a · b** suma los productos de las componentes correspondientes. La norma **‖a‖** es la raíz cuadrada de la suma de los cuadrados de las componentes de **a**. El cálculo requiere que ambos vectores tengan la misma dimensión y una norma distinta de cero.

Ejemplo de cálculo

Tomemos **a = (3, 4)** y **b = (4, 3)**. Su producto escalar es 3 × 4 + 4 × 3 = 24. Las dos normas valen √25 = 5. Por lo tanto, la similitud coseno es **24 / (5 × 5) = 0,96**. El resultado indica que apuntan en direcciones cercanas.

1	0	−1
Misma dirección	Perpendiculares	Direcciones opuestas

Una similitud cercana a 1 indica alineación en el espacio del modelo. En una búsqueda de textos, el resultado sirve para ordenar candidatos y revisar qué fragmentos contienen la información buscada.

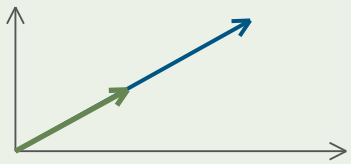
Referencias de clase. Diapositiva 32. Transcripción, 20:32–21:00 y 31:55–32:15.

Qué pasa con la magnitud

Vectores con la misma dirección

La normalización del coseno hace que el resultado sea insensible a un cambio de escala positivo. Si multiplicamos todas las componentes de un vector por el mismo número positivo, su dirección se conserva y su longitud cambia.

La clase lo ilustra con dos personas y dos géneros de series. Una vio **1 romántica y 1 de terror**, y la otra vio **100 románticas y 100 de terror**. Los vectores (1, 1) y (100, 100) tienen la misma dirección. Su similitud coseno vale **1**.



a = (1, 1)

b = (100, 100)

Vectores en la misma dirección. Esquema sin escala.

Si queremos comparar **la proporción de preferencias**, el coseno refleja que ambas personas miran los dos géneros en la misma proporción. Si importa **cuántas series vieron**, el volumen de actividad debe considerarse por separado. La similitud coseno conserva la dirección y descarta la magnitud.

Fuentes de la clase

Clase 2 - Transformación de Texto a Embeddings. Diapositivas 31–35. Definición, similitud coseno y tipos de embeddings.

Transcripción embeddings_2.VTT. 18:32–18:50 y 25:22–25:38, representación. 20:32–21:00 y 31:55–32:15, similitud y cálculo. 25:38–27:14, magnitud y series. 27:47–28:45, embeddings estáticos y contextuales.